Warunkowe uzasadnienie przewagi planowania rolling horizon w długich projektach IT

Streszczenie

Celem tekstu jest sformułowanie matematycznie obronialnego, warunkowego argumentu za stosowaniem planowania typu *rolling horizon* (szczegółowy plan na najbliższe dwa sprinty, dalszy horyzont utrzymywany na poziomie epików/celów) w długich projektach IT. Nie dowodzimy wyższości absolutnej nad każdym wariantem planowania statycznego. Pokazujemy natomiast, że dla klasy modeli z niepewnymi (asymetrycznymi) czasami zadań, dodatnimi korelacjami oraz punktami synchronizacji, podejście rolling horizon redukuje wariancję błędu prognozy i zwykle zmniejsza ryzyko opóźnień względem planowania szczegółowego na cały horyzont projektu bez regularnej aktualizacji estymat.

1 Wprowadzenie i cel porównania

Rozważamy długie projekty IT (np. trwające co najmniej 6 miesięcy), w których:

- czasy zadań są niepewne i asymetryczne,
- występują zależności sekwencyjne i równoległe,
- projekt jest podatny na kumulację błędów estymacji.

Porównujemy dwie polityki planowania:

Definicja 1 (Polityka A: plan statyczny długohoryzontowy)**.** Na początku projektu tworzony jest szczegółowy harmonogram mikro-zadań na cały horyzont projektu (wraz z datami końca). W analizowanym modelu nie zakładamy regularnej probabilistycznej aktualizacji parametrów estymacji w reakcji na dane z realizacji.

Definicja 2 (Polityka B: rolling horizon (2 sprinty))**.** Szczegółowy plan utrzymywany jest wyłącznie dla najbliższych dwóch sprintów. Po każdym sprincie estymaty są aktualizowane na podstawie danych z realizacji, natomiast dalsza część projektu utrzymywana jest na poziomie epików/celów (plan agregowany).

Cel. Nie dowodzimy tezy absolutnej typu "B zawsze lepsze od A". Dowodzimy twierdzenia warunkowego: w określonej klasie modeli niepewności polityka B ma mniejszą wariancję błędu prognozy i zwykle mniejsze ryzyko opóźnienia niż polityka A.

2 Założenia modelu

2.1 Czasy trwania zadań

Niech $X_i > 0$ oznacza rzeczywisty czas wykonania zadania i. Zakładamy, że dla wielu zadań IT sensownym modelem jest rozkład log-normalny:

$$X_i \sim \text{Lognormal}(\mu_i, \sigma_i^2), \qquad \text{tj. } \ln X_i \sim \mathcal{N}(\mu_i, \sigma_i^2).$$

Model ten odzwierciedla:

- dodatniość czasu trwania,
- asymetrię rozkładu,
- możliwość rzadkich, dużych opóźnień.

2.2 Struktura projektu

Projekt zawiera:

- fragmenty sekwencyjne (czas jako suma),
- punkty synchronizacji (merge/join), w których kolejne zadanie czeka na zakończenie wielu gałęzi.

Jeśli zadanie C może rozpocząć się dopiero po zakończeniu gałęzi A i B, to:

$$T_C^{\text{start}} = \max(T_A, T_B).$$

2.3 Metryki porównania polityk

Porównujemy polityki za pomocą:

$$\text{(M1)} \quad \text{Var}(\widehat{T} - T), \tag{1}$$
$$\text{(M2)} \quad \mathbb{P}(T > D), \tag{2}$$

gdzie:

- T – rzeczywisty czas ukończenia projektu,
- $\widehat{T}$ – prognozowany czas ukończenia,
- D – zadany deadline.

3 Lematy pomocnicze

Lemat 1 (Moment pierwszy i wariancja rozkładu log-normalnego)**.** *Jeśli* $X \sim \text{Lognormal}(\mu, \sigma^2)$, *to:*

$$\mathbb{E}[X] = e^{\mu + \sigma^2/2}$$

oraz

$$\text{Var}(X) = e^{2\mu + \sigma^2}(e^{\sigma^2} - 1).$$

Dowód. Ponieważ $\ln X \sim \mathcal{N}(\mu, \sigma^2)$, można zapisać $X = e^Y$, gdzie $Y \sim \mathcal{N}(\mu, \sigma^2)$. Z własności funkcji tworzącej momenty rozkładu normalnego:

$$\mathbb{E}[e^{tY}] = \exp\left(t\mu + \frac{t^2\sigma^2}{2}\right).$$

Dla $t = 1$ otrzymujemy:

$$\mathbb{E}[X] = \mathbb{E}[e^Y] = e^{\mu+\sigma^2/2}.$$

Dla $t = 2$ dostajemy:

$$\mathbb{E}[X^2] = \mathbb{E}[e^{2Y}] = e^{2\mu+2\sigma^2}.$$

Zatem:

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = e^{2\mu+2\sigma^2} - e^{2\mu+\sigma^2} = e^{2\mu+\sigma^2}(e^{\sigma^2} - 1).$$

□

Wniosek 1 (Koszt niepewności)**.** *Dla ustalonego μ, wzrost σ^2 zwiększa zarówno $\mathbb{E}[X]$, jak i $\mathrm{Var}(X)$. W szczególności wzrost wariancji ma charakter nieliniowy.*

Dowód. Wynika bezpośrednio z postaci wzorów z Lematu 1. □

Lemat 2 (Kumulacja wariancji na fragmencie sekwencyjnym)**.** *Niech*

$$T_{\mathrm{seq}} = X_1 + \cdots + X_m.$$

Wtedy:

$$\mathrm{Var}(T_{\mathrm{seq}}) = \sum_{i=1}^{m} \mathrm{Var}(X_i) + 2 \sum_{1 \le i < j \le m} \mathrm{Cov}(X_i, X_j).$$

Dowód. Jest to standardowa własność wariancji sumy zmiennych losowych. □

Wniosek 2 (Wpływ dodatnich korelacji)**.** *Jeżeli $\mathrm{Cov}(X_i, X_j) \ge 0$ dla wielu par (i, j), to wariancja czasu fragmentu sekwencyjnego rośnie szybciej niż w przypadku niezależności.*

Dowód. Bezpośrednio z Lematu 2, ponieważ dodatkowy składnik kowariancyjny jest nieujemny. □

Lemat 3 (Koszt punktu synchronizacji)**.** *Dla dowolnych zmiennych losowych U, V o skończonych wartościach oczekiwanych zachodzi:*

$$\mathbb{E}[\max(U, V)] \ge \max(\mathbb{E}[U], \mathbb{E}[V]).$$

Dowód. Ponieważ $\max(U, V) \ge U$ oraz $\max(U, V) \ge V$ prawie na pewno, po wzięciu wartości oczekiwanej otrzymujemy:

$$\mathbb{E}[\max(U, V)] \ge \mathbb{E}[U], \qquad \mathbb{E}[\max(U, V)] \ge \mathbb{E}[V].$$

Stąd teza. □

Wniosek 3 (Merge bias)**.** *Punkty synchronizacji zwiększają oczekiwany czas realizacji względem naiwnego rozumowania opartego wyłącznie na średnich poszczególnych gałęzi.*

Dowód. Jeżeli zadanie może ruszyć dopiero po zakończeniu dwóch gałęzi, jego czas startu wynosi $\max(T_A, T_B)$. Z Lematu 3:

$$\mathbb{E}[T_{\text{join}}] = \mathbb{E}[\max(T_A, T_B)] \geq \max(\mathbb{E}[T_A], \mathbb{E}[T_B]).$$

□

Lemat 4 (Aktualizacja estymacji zmniejsza niepewność parametru)**.** *Rozważmy uproszczony model:*

$$\theta \sim \mathcal{N}(m_0, \tau_0^2),$$

gdzie θ oznacza parametr efektywności (np. tempo realizacji). Niech obserwacje z kolejnych sprintów mają wariancję σ^2 i prowadzą do standardowej aktualizacji normalnej. Po n obserwacjach wariancja posteriori spełnia:

$$\frac{1}{\tau_n^2} = \frac{1}{\tau_0^2} + \frac{n}{\sigma^2},$$

a więc

$$\tau_n^2 = \frac{\sigma^2 \tau_0^2}{\sigma^2 + n\tau_0^2} < \tau_0^2 \qquad \text{dla } n \geq 1.$$

Dowód. Jest to standardowy wynik dla modelu normalnego z normalnym priorem (sprzężenie Bayesowskie). Nierówność wynika z dodatniości $n\tau_0^2$ w mianowniku. □

Wniosek 4 (Wartość danych z pierwszych sprintów)**.** *Po uzyskaniu danych z 1–2 sprintów zmniejsza się niepewność estymacji parametru efektywności, co może poprawić jakość prognozy dalszej części projektu.*

Dowód. Bezpośrednio z Lematu 4: mniejsza wariancja posteriori oznacza większą precyzję estymacji parametru. □

4 Twierdzenie główne

Twierdzenie 1 (Warunkowa przewaga rolling horizon)**.** *Rozważmy długi projekt IT, którego czas realizacji T zależy od:*

(i) dodatnich, asymetrycznych czasów zadań (np. log-normalnych),

(ii) fragmentów sekwencyjnych oraz punktów synchronizacji,

(iii) dodatnich korelacji pomiędzy częścią zadań.

Załóżmy dodatkowo, że:

(A1) polityka A (plan statyczny) nie aktualizuje regularnie probabilistycznie parametrów estymacji na podstawie danych z realizacji,

(A2) polityka B (rolling horizon) aktualizuje estymaty po każdym sprincie i utrzymuje szczegółowy plan wyłącznie dla najbliższych dwóch sprintów,

(A3) dalszy horyzont w polityce B utrzymywany jest na poziomie epików/celów (plan agregowany), co ogranicza koszty fałszywej precyzji mikrodat.

Wówczas, dla projektów o istotnej niepewności i dostatecznie długim horyzoncie:

(a) polityka B ma mniejszą wariancję błędu prognozy niż polityka A (w metryce M1),

(b) a w typowych warunkach również mniejsze ryzyko opóźnienia $\mathbb{P}(T > D)$ (metryka M2), ponieważ decyzje planistyczne są podejmowane przy większej ilości informacji.

Uzasadnienie krok po kroku. **Krok 1.** Z Lematu 1 i Wniosku 1 wynika, że niepewność czasu zadań (parametr σ^2) zwiększa zarówno średni czas, jak i wariancję. Oznacza to, że szczegółowa predykcja mikro-zadań w dalekim horyzoncie jest obarczona rosnącym kosztem niepewności.

Krok 2. Z Lematu 2 i Wniosku 2 wynika, że na długich ścieżkach sekwencyjnych błędy estymacji kumulują się przez sumę wariancji i kowariancji. Zatem im dłuższy odcinek projektu planowany z mikroszczegółowością, tym większa kruchość harmonogramu.

Krok 3. Z Lematu 3 i Wniosku 3 wynika, że punkty synchronizacji (merge/join) dodatkowo podnoszą oczekiwany czas. W praktyce zwiększa to ryzyko odchyleń od sztywnego harmonogramu.

Krok 4. Z Lematu 4 i Wniosku 4 wynika, że po pozyskaniu danych z pierwszych sprintów maleje niepewność estymacji parametru efektywności. Polityka B wykorzystuje tę informację do aktualizacji prognoz; polityka A (zgodnie z założeniem A1) tego nie robi.

Krok 5. Polityka B ogranicza szczegółowość planowania do najbliższego horyzontu (2 sprinty), w którym:

- estymaty opierają się na świeższych danych,
- koszty korekty planu są niższe,
- skala kumulacji błędów jest mniejsza niż w planowaniu mikroszczegółowym na cały projekt.

Dalszy horyzont pozostaje planowany agregacyjnie (epiki/cel), co ogranicza ryzyko nadmiernych mikrozobowiązań opartych na słabej informacji.

Krok 6. W konsekwencji polityka B, dzięki (i) regularnej aktualizacji estymat i (ii) ograniczeniu szczegółowości tam, gdzie niepewność jest największa, redukuje wariancję błędu prognozy względem polityki A (metryka M1). W typowych warunkach przekłada się to również na niższe ryzyko opóźnienia $\mathbb{P}(T > D)$, ponieważ kolejne decyzje są podejmowane przy lepszej informacji niż na starcie projektu.

Twierdzenie ma charakter warunkowy i obowiązuje w granicach przyjętego modelu oraz założeń porównawczych. □

5 Zakres ważności i ograniczenia

Uwaga 1 (Czego twierdzenie nie dowodzi). Twierdzenie 1 nie dowodzi, że:

- podejście agile/rolling horizon jest zawsze lepsze od każdego wariantu waterfall,
- dokładnie dwa sprinty są uniwersalnym optimum dla każdej organizacji,

- wszystkie metryki projektowe (koszt, jakość, zakres, compliance) poprawiają się jednocześnie.

Uwaga 2 (O "2 sprintach"). Wybór horyzontu "2 sprintów" należy traktować jako praktyczny kompromis, a nie wynik absolutnego dowodu matematycznego. Aby udowodnić optimum, należałoby zdefiniować funkcję kosztu:

$$J(h) = C_{\text{replan}}(h) + C_{\text{forecast-error}}(h),$$

a następnie wykazać, że minimum $J(h)$ wypada przy $h = 2$ dla konkretnej klasy organizacji/projektów.

6 Wniosek końcowy

W długich projektach IT o istotnej niepewności czasów zadań, dodatnich korelacjach i punktach synchronizacji, szczegółowe planowanie całego projektu na starcie prowadzi do kumulacji błędów prognozy. Planowanie typu rolling horizon (szczegółowy plan na najbliższe dwa sprinty, dalszy horyzont na poziomie epików/celów) wykorzystuje aktualizację informacji z realizacji i ogranicza fałszywą precyzję w dalekim horyzoncie. W przyjętym modelu daje to przewagę w metrykach ryzyka prognozy i zwykle w ryzyku opóźnień.

A Dodatek: słownik symboli i oznaczeń

Poniższy słownik zbiera najważniejsze symbole użyte w tekście. Celem dodatku jest ułatwienie czytania argumentu także osobom nietechnicznym (np. interesariuszom biznesowym lub kadrze menedżerskiej).

A.1 Podstawowe zmienne

X	Zmienna losowa reprezentująca czas trwania pojedynczego zadania.
X_i	Czas trwania zadania numer i (np. $X_1, X_2, \ldots$).
T	Rzeczywisty czas ukończenia projektu (lub analizowanego fragmentu projektu).
$\widehat{T}$	Prognozowany (oszacowany) czas ukończenia projektu.
D	Deadline, tj. termin docelowy / uzgodniona data zakończenia.

A.2 Operatory probabilistyczne i statystyczne

$\mathbb{E}[X]$	Wartość oczekiwana zmiennej X, czyli średnia (w sensie probabilistycznym).
$\mathrm{Var}(X)$	Wariancja zmiennej X, czyli miara rozrzutu wartości wokół średniej.
$\mathrm{Cov}(X, Y)$	Kowariancja zmiennych X i Y, opisująca współzależność ich zmian.
$\mathbb{P}(A)$ **lub** $\mathbb{P}(A)$	Prawdopodobieństwo zdarzenia A.

$P(T > D)$ Prawdopodobieństwo opóźnienia projektu (szansa, że projekt zakończy się po terminie).

μ Parametr położenia rozkładu. W modelu log-normalnym użytym w tekście jest to średnia zmiennej $\ln X$, a nie bezpośrednio średnia czasu X.

σ Parametr skali / odchylenie standardowe (w zależności od kontekstu).

σ^2 Wariancja (często parametr niepewności w modelu).

τ_0^2 Wariancja początkowa (prior) parametru w modelu Bayesowskim.

τ_n^2 Wariancja po aktualizacji (posterior) po uwzględnieniu n obserwacji.

θ Ukryty parametr efektywności (np. tempo realizacji zespołu) estymowany na podstawie danych z kolejnych sprintów.

A.3 Rozkłady i notacja rozkładów

$\mathcal{N}(\mu, \sigma^2)$ Rozkład normalny (Gaussa) o średniej μ i wariancji σ^2.

$\text{Lognormal}(\mu, \sigma^2)$
Rozkład log-normalny; oznacza, że logarytm zmiennej ma rozkład normalny.

$X \sim \text{Lognormal}(\mu, \sigma^2)$
Zmienna X ma rozkład log-normalny.

$\ln X$ Logarytm naturalny zmiennej X.

A.4 Operatory matematyczne użyte w modelu projektu

$\sum$ Symbol sumowania, np.

$$\sum_{i=1}^{m} X_i = X_1 + X_2 + \cdots + X_m.$$

W tekście opisuje m.in. sumę czasów na fragmencie sekwencyjnym projektu.

$\max(U, V)$ Większa z dwóch wartości U i V. W modelu projektu opisuje punkty synchronizacji (join/merge), gdzie dalsza praca może ruszyć dopiero po zakończeniu najwolniejszej gałęzi.

A.5 Symbole porównań

$<$ Mniejsze niż.

$>$ Większe niż.

$\leq$ Mniejsze lub równe.

$\geq$ Większe lub równe.

A.6 Najważniejsze wielkości interpretacyjne (perspektywa praktyczna)

W kontekście zarządzania projektem szczególnie użyteczne są trzy wielkości:

- $\mathbb{E}[T]$ – **średni oczekiwany czas zakończenia projektu**,
- $\mathrm{Var}(T)$ – **miara niepewności / rozrzutu czasu zakończenia**,
- $\mathbb{P}(T > D)$ – **ryzyko opóźnienia względem deadline'u**.

Interpretacyjnie:

- $\mathbb{E}[T]$ mówi *kiedy średnio kończymy*,
- $\mathrm{Var}(T)$ mówi *jak bardzo ten termin może się wahać*,
- $\mathbb{P}(T > D)$ mówi *jakie jest ryzyko niedotrzymania terminu*.